소프트웨어시험

신청자(의뢰자) 제시 기준 확인서

회사명	레인보우	연락처	010-8597-6322
제품명	AI 업무패턴분석 기반 테스트 시나리오 및 업무 프로세스맵 자동생성 플랫폼 v1.0	시험항목수	7 건

1. 시험대상 품목

1.1 시험대상 제품 (의뢰자 제공)

제품명 (버전 포함)	제조사
AI 업무패턴분석 기반 테스트 시나리오 및 업무 프로세스맵 자동생성 플랫폼 v1.0	레인보우

1.2 제품용도 (의뢰자 제시)

- 웹 기반 업무시스템에서 사용자가 수행하는 업무 행위(이벤트)를 수집하고, AI로 정제ㅇ분석하여 반복 업무 패턴을 식별한 후 업무 프로세스맵, 업무 매뉴얼, 테스트 시나리오 및 테스트 스크립트를 자동 생성하고 자동 실행하는 소프트웨어

1.3 제품구성 (의뢰자 제시)

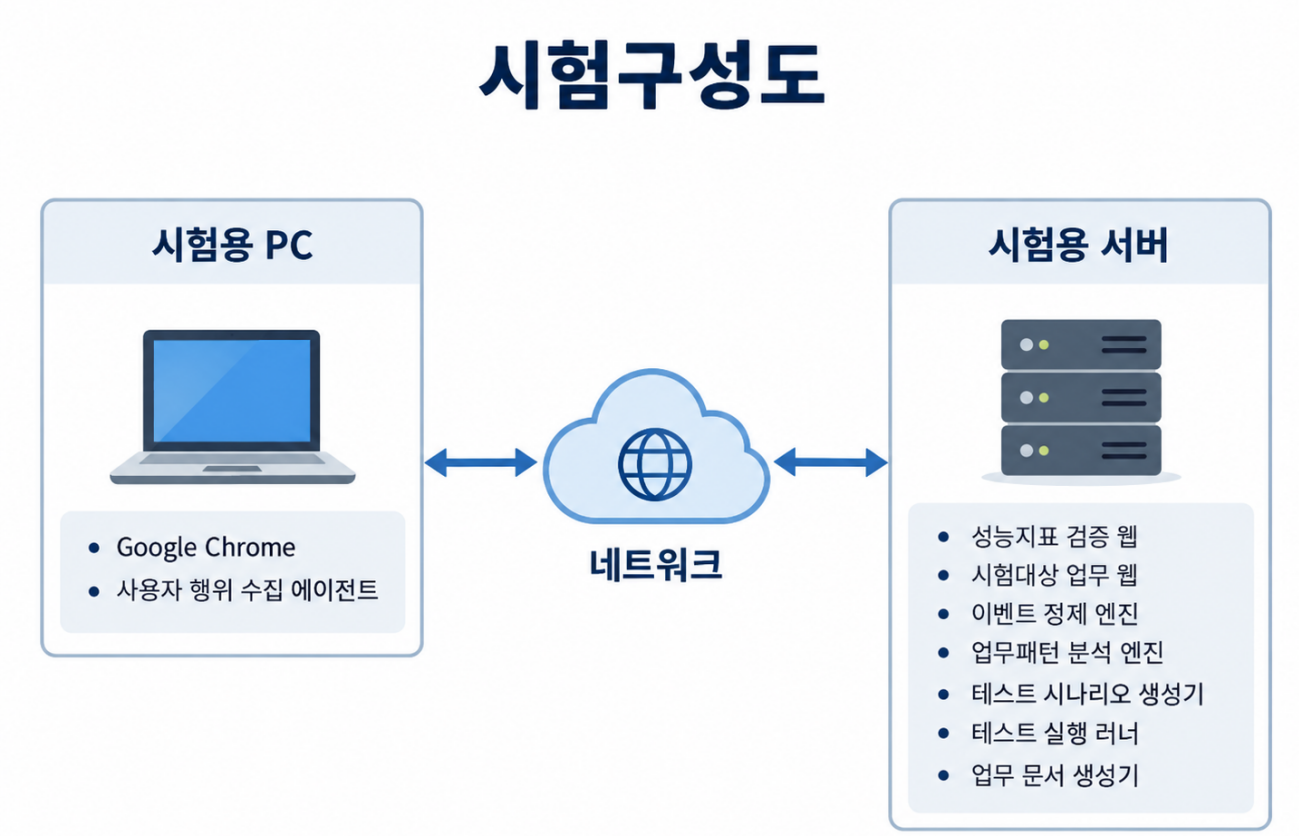
구성요소명 (버전 포함)	용도
사용자 행위 수집 에이전트 v1.0	웹 브라우저에서 클릭, 입력, 화면 전환, 네트워크 요청 등 사용자 이벤트를 수집하여 서버로 전송하는 모듈
업무패턴 분석 엔진 v1.0	딥러닝 모델로 업무 경계를 탐지하고 반복 업무 흐름을 군집화하여 업무 프로세스맵을 생성하는 모듈

2. 시험도구

도구 명	용도
Google Chrome	사용자 행위 수집 에이전트 실행 및 성능지표 검증 웹 접속을 위한 웹 브라우저 (의뢰자 제공 및 제시)
Microsoft Excel	산출 근거 CSV로 측정값을 재계산하여 확인하기 위한 소프트웨어 (의뢰자 제공 및 제시)

3. 시험환경

3.1 시험구성 (의뢰자 제공)



< 시험용 PC의 웹 브라우저에서 시험용 서버의 시험대상 업무 웹을 수행하고, 성능지표 검증 웹에 접속하여 제품 구성요소를 실행한 후 측정값을 확인한다 >

※ 본 시험은 명시된 위 시험환경 내에서 수행되었으며, 시험 결과는 위 시험환경에 국한됨

3.2 하드웨어 및 소프트웨어 환경 (의뢰자 제공)

시험대상	사양	
	OS	Microsoft Windows 11 Pro (64 bit)
	CPU	Intel Core i7-14650HX 2.20 GHz (16코어, 24스레드)
	RAM	32 GB
	STORAGE	KLEVV CRAS C910 2TB NVMe SSD
	NIC	Realtek PCIe GbE Family Controller 1 Gbps
	VGA	NVIDIA GeForce RTX 5060 Laptop GPU 8 GB
	SW	Google Chrome v152.0.7977.82, Rainbow Collector Extension v1.0

시험대상	사양	
	OS	Ubuntu 26.04 LTS (64 bit)
	CPU	Intel Core i7-6900K CPU 3.20 GHz (8 Core / 16 Thread)
	RAM	128 GB
	STORAGE	1TB
	NIC	Intel I211 Gigabit Network Connection 1 Gbps
	VGA	NVIDIA GeForce RTX 3090 24GB
	SW	Docker v29.1.3, Node.js v18.20.8, Python v3.12.3, PyTorch v2.13.0+cu132, MariaDB v11.4.10

시험대상	사양	
	제조사	해당없음
	모델번호	해당없음
	OS버전	해당없음
	SW	해당없음

4. 시험 항목

4.1 시험 항목 1

시험 내용 (의뢰자 제시)
■ 시험항목명: 수집정확도 – 시험 목적: 시험대상 업무 웹에서 사용자가 수행한 클릭, 입력, 선택, 화면 전환 등 필수 행위가 사용자 행위 수집 에이전트에 의해 누락 없이 수집되고, 각 이벤트의 필수 필드가 정상 기록되는지 확인한다. – 시험 기준: 수집정확도 = 0.5×C1 + 0.3×(100−C2) + 0.2×C3, 목표값 65% 이상 – 시험 데이터 (의뢰자 제공): ● TD−01_필수이벤트정의서.xlsx : 시험에 사용할 필수 이벤트 10건을 정의하여 정의한다. ※ 연구개발계획서에는 시험 건수와 반복 횟수가 별도로 명시되어 있지 않으므로, 본 제시기준서에서는 재현성을 위해 필수 이벤트 10 건으로 고정한다. ■ 시험 방법 및 기준(조건): 1. 시험대상 업무 웹 v1.0에 접속한 후 TD−01의 첫 번째 시나리오를 시작한다. 2. TD−01에 기재된 순서대로 클릭, 입력, 선택, 조회, 저장, 팝업 열기 등 사용자 조작을 수행한다. 3. 시나리오 1종을 각각 1회 수행하며, 매 수행은 독립된 수집 세션으로 실행하여 총 10개 수집 세션을 생성한다. 5. 화면에 표시되는 C1(필수 이벤트 수집충족률), C2(필수 필드 누락률), C3(이벤트 유형 커버리지) 및 최종 수집정확도를 확인한다.

4.2 시험 항목 2

시험 내용 (의뢰자 제시)
■ 시험항목명: 프로세스맵 정확도 및 완전성 – 시험 목적: 모델이 사용자 이벤트 로그에서 자동 생성한 업무 프로세스맵이 실제 업무 절차를 얼마나 정확하게 재현하고, 필수 절차를 얼마나 빠짐없이 포함하는지 확인한다. – 시험 기준: 측정지표 = √(Accuracy × Completeness), 목표값 75% 이상 – 시험 데이터 (의뢰자 제공): ● TD−03_평가용이벤트로그.csv : 가명처리된 웹 업무시스템 사용자 이벤트 로그. 시험용 업무단위 20종의 수행 로그를 포함하며, 이 중 M02 평가 대상 Ground Truth 업무 프로세스 5종을 포함한다. 원시 이벤트 건수는 업무별 절차 길이에 따라 달라질 수 있으므로 전체 업무단위 20종을 데이터 수량 기준으로 고정한다. ● TD−04_정답프로세스정의서.xlsx : process_id, 업무명, 필수 절차 ID, 메뉴/화면명, 절차 순서, 허용 별칭을 정의한 정답 파일

● 성적서용 Ground Truth 업무 프로세스는 5종으로 고정한다.
※ 연구개발계획서에는 시험 프로세스 수가 별도로 명시되어 있지 않으므로, 본 제시기준서에서는 프로세스맵 성능평가 대상을 Ground Truth 5종으로 고정한다. 원시 이벤트 건수는 성능지표의 직접 분모가 아니므로 별도 목표 건수로 제한하지 않는다.

■ 시험 방법 및 기준(조건):

1. 시험용 데이터의 Ground Truth 업무 시나리오와 필수 절차 목록을(TD-04) 성능평가 프로그램에등록한다.
2. 동일 업무 시나리오의 이벤트 로그를(TD-03) AI 업무패턴 분석 엔진에 입력하여 프로세스맵을 생성한다.
3. 생성 프로세스맵의 각 절차와 Ground Truth 절차를 사전 정의된 매핑 기준으로 비교한다.
4. Accuracy = 정확히 매핑된 절차 수 / 생성 프로세스맵의 전체 절차 수 × 100으로 계산한다.
5. Completeness = 포함된 필수절차 수 / Ground Truth로 정의된 전체 필수절차 수 × 100으로 계산한다.
6. √(Accuracy × Completeness)를 산출하고 75% 이상인지 확인한다.
7. 참고용 보조근거(input label, node evidence 등)는 화면 설명에는 사용할 수 있으나 성적서의 직접 매핑 정답 수에는 포함하지 않는다.

4.3 시험 항목 3

시험 내용 (의뢰자 제시)
■ 시험항목명: 테스트 시나리오 자동생성 비율 – 시험 목적: 평가용 업무 로그에서 식별된 업무단위 중 제품이 테스트 시나리오를 자동으로 생성할 수 있는 업무단위의 비율을 확인한다. – 시험 기준: 자동생성 비율 = 자동생성 성공 시나리오 수 / 전체 업무단위 수 × 100, 목표값 80% 이상 – 시험 데이터 (의뢰자 제공): ● TD-03_평가용이벤트로그.csv : 시험 항목 2와 동일 ● TD-05_업무단위정의서.xlsx : business_unit_id, 업무명, 시작 화면, 필수 수행 화면/절차, 종료 조건을 정의한 시험용 업무단위 10 종의 목록 ※ 연구개발계획서에는 전체 업무단위 수 또는 시나리오 생성 반복 횟수가 별도로 명시되어 있지 않으므로, 본 제시기준서에서는 10건을 평가한다. ■ 시험 방법 및 기준(조건): 1. 시험용 전체 업무단위 목록을(TD-05) 성능평가 프로그램에 등록한다. 2. 각 업무단위를 테스트 시나리오 자동생성 모듈에 순차 입력한다. 3. 자동 생성된 시나리오가 사전에 정의된 JSON Schema 및 필수항목을 만족하는지 검증한다. 4. 필수항목이 존재하고 단계 순서 및 action/target 정보가 생성된 경우 자동생성 성공 1건으로 판정한다. 5. 자동생성 성공 시나리오 수 / 전체 업무단위 수 × 100으로 자동생성 비율을 계산한다. 6. 자동생성 비율이 80% 이상인지 확인한다.

4.4 시험 항목 4

시험 내용 (의뢰자 제시)
■ 시험항목명: 자동실행 성공률 – 시험 목적: 자동 생성된 테스트 스크립트가 별도의 시험대상 업무 웹에서 처음부터 마지막 단계까지 정상 자동 실행되는 비율을 확인한다. – 시험 기준: 자동실행 성공률 = 정상 완료된 테스트 수 / 전체 자동 실행 테스트 수 × 100, 목표값 90% 이상 – 시험 데이터 (의뢰자 제공): ● TD-08_자동실행스크립트세트.zip : 제품의 테스트 시나리오 생성기/LLM 모듈로 사전 생성하고 수동 수정 없이 시험 전에 고정한 Selenium 기반 Python 테스트 스크립트 10건. 각 스크립트에는 scenario_id와 기대 결과(assert)를 포함한다.

● 시험대상 업무 웹 v1.0 : 로그인, 조회, 입력, 선택, 저장, 팝업 등 자동화 수행 대상 기능이 구성된 시험용 웹

※ 연구개발계획서에는 자동 실행 테스트 건수 또는 반복 실행 횟수가 별도로 명시되어 있지 않으므로, 본 제시 기준서 에서는 고정 스크립트 10건을 한번에 자동 실행하여 평가한다.

■ 시험 방법 및 기준(조건):

1. 성능시험용 웹 애플리케이션과 Selenium Runner를 실행한다.
2. 검증된 테스트 시나리오를 Runner에 입력하여 수동 개입 없이 자동 실행한다.
3. 각 시나리오의 필수 단계가 모두 수행되고 기대 결과가 확인되면 정상 완료(PASS)로 판정한다.
4. 단계 실행 오류, 요소 미탐지, 예상 결과 불일치 또는 실행 중단이 발생하면 FAIL로 판정하고 실패 단계와 오류 메시지를 기록한다.
5. 정상 완료된 테스트 수 / 전체 자동 실행 테스트 수 × 100으로 자동실행 성공률을 계산한다.
6. 자동실행 성공률이 90% 이상인지 확인한다.

4.5 시험 항목 5

시험 내용 (의뢰자 제시)
■ 시험항목명: AI 기반 정제 F1 Score – 시험 목적: 수집 이벤트 중 업무 분석에 불필요한 노이즈 이벤트 및 중복 이벤트를 AI 정제 엔진이 얼마나 정확하게 제거 대상으로 판정하는지 확인한다. – 시험 기준: F1 = 2×Precision×Recall / (Precision+Recall), 목표값 0.79 이상 – 시험 데이터 (의뢰자 제공): ● TD-06_정제평가용이벤트로그.csv : 모델 학습 및 개발에 사용하지 않은 가명처리 이벤트 20건으로 고정한다. 정제대상(remove) 10건과 유지대상(keep) 100건으로 균형 구성한다. ● TD-07_정제정답라벨.csv : 200개 event_id별 정답 라벨을 정의한다. remove 100건은 duplicate 25건, noise 25건, repeated_action 25건, irrelevant_action 25건으로 구성하고 keep 100건을 포함한다. ※ 연구개발계획서에는 정제 평가용 이벤트 건수 또는 반복 측정 횟수가 별도로 명시되어 있지 않으므로, 본 제시기준서에서는 총 200건의 고정 라벨 데이터셋을 1회 일괄 평가한다. ■ 시험 방법 및 기준(조건): 1. 정답 라벨이 포함된 시험용 이벤트 데이터셋을 AI 정제 모듈에 입력한다. 2. AI 정제 모듈이 각 이벤트에 대해 정제대상/유지대상을 판정하도록 한다. 3. TP = 실제 정제대상을 정제대상으로 판정, FP = 유지대상을 정제대상으로 오판정, FN = 정제대상을 유지대상으로 누락한 건수로 집계한다. 4. Precision = TP / (TP+FP), Recall = TP / (TP+FN)으로 계산한다. 5. F1 Score = 2×Precision×Recall / (Precision+Recall)로 계산한다.

6. F1 Score가 0.79 이상인지 확인한다.

4.6 시험 항목 6

시험 내용 (의뢰자 제시)
■ 시험항목명: 시나리오 흐름 군집 품질 평가(DBI) - 시험 목적: 업무패턴 분석 엔진이 추출한 업무 흐름 임베딩이 동일 군집 내에서는 가깝고 서로 다른 군집 간에는 충분히 분리되어 있는지 Davies-Bouldin Index(DBI)로 확인한다. - 시험 기준: Davies-Bouldin Index(DBI) 1.0 이하 (낮을수록 우수) - 시험 데이터 (의뢰자 제공): AI 업무패턴 분석 엔진의 workflow embedding과 cluster label ■ 시험 방법 및 기준(조건): 1. 모델 결과에서 workflow embedding 벡터와 각 workflow의 cluster label을 시험데이터로 준비한다. 2. 성능측정 프로그램에서 각 군집의 중심점과 군집 내부 산포도(Si)를 계산한다. 3. 각 군집 중심 간 거리(Mij)를 계산하고 군집별 최대 (Si+Sj)/Mij 값을 구한다. 4. DBI = (1/n)×Σ max((Si+Sj)/Mij), j≠i 식에 따라 전체 군집의 Davies-Bouldin Index를 계산한다. 5. 동일 계산을 scikit-learn의 davies_bouldin_score와 교차 확인한다. 6. DBI가 1.0 이하인지 확인한다.

4.7 시험 항목 7

시험 내용 (의뢰자 제시)
■ 시험항목명: LLM 생성코드의 유효성 및 정확성 - 시험 기준: 유효성 및 정확성 = C1 / C2 × 100, 목표값 80% 이상. C1 = 문법검사 PASS 및 실행테스트 PASS를 모두 만족한 코드 수, C2 = LLM이 생성한 전체 코드 수 - 시험 데이터 (의뢰자 제공): 의뢰자 제공 테스트 시나리오 세트, LLM 코드 생성 프롬프트/설정, 성능시험용 웹 애플리케이션, 시나리오별 기대 결과. 생성 코드는 Selenium 기반 Python 테스트 코드 형식으로 고정 ■ 시험 방법 및 기준(조건): 1. 각 테스트 시나리오를 LLM 코드 생성 모듈에 입력하여 Selenium 기반 Python 테스트 코드를 생성한다.

2. 각 테스트 시험 시나리오 20종을 각각 1회씩 입력하여 총 20개의 Selenium 기반 테스트코드를 생성하며, 전체 생성 코드 수(C2)는 20건으로 고정한다.
3. 생성된 코드를 Python AST 또는 py_compile 방식으로 문법 검사하고 PASS/FAIL을 기록한다.
4. 문법검사 PASS 코드를 M04와 동일한 Selenium Runner 및 성능시험용 웹 애플리케이션에서 실행한다.
5. 모든 필수 단계가 실행되고 기대 결과가 확인된 경우 실행테스트 PASS로 판정한다.
6. 문법검사와 실행테스트를 모두 PASS한 코드 수(C1)를 집계한다.
7. C1 / 전체 생성 코드 수(C2) × 100으로 유효성 및 정확성을 산출하고 80% 이상인지 확인한다.

소프트웨어 시험을 의뢰한 상기 제품에 대하여,
신청자(의뢰자) 제시 기준(규격) 및 시험방법을 위와 같이 제출합니다.

2026년 9월 18일

업무담당자 최인화 (서명 또는 직인)

※ 반드시 소프트웨어시험 신청서와 동일한 서명/직인이어야 합니다.

ktl 한국산업기술시험원장 귀하